# Paper seminar

2025-08-22

Department of Metaverse Convergence at Chung-Ang University Myungjun Yun



# **Background**

### Monocular depth estimation

- Single view를 입력으로 받아 2D image에서 3D depth value를 알아내는 task
- Metaverse, Autonomous driving, Robotics등 다양한 분야에서 응용
- 최근에는 Foundation model의 발전으로 인해 높은 성능을 달성




#### **Background**

- Open-world scenarios에서 Video depth estimation은 어려움(객체의 움직임, 길이)
- 기존의 방법은 Video**의 시간적 정보 고려를 하지 않아 Flickering** 발생
- Camera movement, long sequences, motion 같은 추가 정보 없이 depth sequence를 생성하는 방법 필요




#### **Purpose**

- Detail & 시간적으로 일관된 long depth sequences를 생성
- 길고 가변적인 시간적 맥락을 가진 long depth sequences 생성을 가능하게 하는 3단계 훈련 전략
- 110 frames 초과 비디오는 **Segment 단위로 처리 후 매끄럽게 연결하는** 추론 전략




#### Method

- Detail & 시간적으로 일관된 long depth sequences를 생성
- 길고 가변적인 시간적 맥락을 가진 long depth sequences 생성을 가능하게 하는 3단계 훈련 전략
- 110 frames 초과 비디오는 **Segment 단위로 처리 후 매끄럽게 연결하는** 추론 전략




#### Method




#### Method


**Encoding & Condition Information Extraction** 



#### Method




#### Method



#### Method

Three-stage training



#### Method

#### **Diffusion model**

- SVD(stable video diffusion)
- Video Conditioning

 $x_t$ : Noised data

 $x_0$ : raw data

 $\sigma_t$ :Noise level

ε: Normal distribution.

 $E_{x_t}$ : Expected value.

 $p(X; \sigma_t)$ : The probability distribution of the noised data  $x_t$  given the noise coefficient.  $p(\sigma)$ :Distribution sampling noise coefficient during training

 $\lambda_{\sigma_t}$ : Weighting based on noise coefficient

 $D_{\theta}$ : Denoiser function


c: Condition

 $c_{skip}$ : Adjust the strength of skip connections based on the noise level.

 $c_{out}$ : Scale the output of  $F_{\theta}$ 

 $c_{in}$ : Adjust data  $x_t$  with added noise in the input to U-net.


 $c_{noise}$ : Mapping noise levels to U\_net conditioning inputs




#### Method

#### Three-stage training

- 다양한 길이의 Open-world video에 대한 고품질 깊이 시퀀스를 생성
- 가변적인 긴 시간적 문맥의 어려움









#### Method


- Pre-trained SVD 모델을 비디오-깊이 생성 작업에 적응
- Large realistic dataset



#### Method

- 긴 시간적 문맥을 처리하고, 길고 가변적인 시퀀스에 대한 전체 깊이 분포를 정확하게 배열
- Large realistic dataset






#### Method

- 합성 데이터셋의 장점을 활용하여 더 정밀한 깊이 디테일을 학습
- Small synthetic dataset








#### Method

#### **Inference for Extremely Long Videos**

- 모델이 학습 후 110 Frames 까지 추정할 수 있지만 Open-World Video에서는 여전히 부족
- Long depth sequence를 Segment 방식으로 추론, 연결




#### Result

#### **Qualitative results**

• 다양한 Open-world videos에서 시간적으로 일관된 깊이 시퀀스를 생성





#### Result

#### **Qualitative results**

- 여러 데이터셋에서 SOTA 달성
- KITTI, Sintel: Camera motion, Fast-moving object
- Scannet, Bonn: Indoor dataset
- Three-stage training이 진행될수록 높은 성능 달성

	stage 1	stage 2	stage 3
AbsRel $\downarrow$ $\delta_1 \uparrow$	0.322	0.316	0.270
	0.626	0.675	0.697

Method	Sintel (~50 frames)		Scannet (90 frames)		KITTI (110 frames)		Bonn (110 frames)		NYU-v2 (1 frame)	
	AbsRel ↓	$\delta_1 \uparrow$	AbsRel↓	$\delta_1 \uparrow$	AbsRel↓	$\delta_1 \uparrow$	AbsRel↓	$\delta_1 \uparrow$	AbsRel ↓	$\delta_1 \uparrow$
NVDS [63]	0.408	0.483	0.187	0.677	0.253	0.588	0.167	0.766	0.151	0.780
ChronoDepth [54]	0.587	0.486	0.159	0.783	0.167	0.759	0.100	0.911	0.073	0.941
Marigold [32]	0.532	0.515	0.166	0.769	0.149	0.796	0.091	0.931	0.070	0.946
Depth-Anything [67]	0.325	0.564	0.130	0.838	0.142	0.803	0.078	0.939	0.042	0.981
Depth-Anything-V2 [68]	0.367	0.554	0.135	0.822	<u>0.140</u>	<u>0.804</u>	0.106	0.921	0.043	0.978
DepthCrafter (Ours)	0.270	0.697	0.123	0.856	0.104	0.896	0.071	0.972	0.072	0.948

#### Conclusion

- Video diffusion model을 활용하는 새로운 Open-world video 깊이 추정 방법인 DepthCrafter 제안
- 추가 정보 없이 다양한 모션 및 카메라 움직임을 가진 비디오에 대해 **디테일과 시간적으로 일관된 깊이 시퀀스**를 생성
- 1 Frame에서 긴 비디오에 이르기까지 다양한 길이의 비디오 지원

#### **Discussion**

- 높은 계산량 및 메모리 소비량
- CLIP 모델이 사전에 학습하지 못한 특정 도메인에서는 낮은 정확도 우려
- dToF 같은 센서 데이터를 사용하지 않아서 거울이나 눈밭 같이 텍스처가 없는 환경에서 작동 우려

Table 3. Inference time per frame (ms) of our model, Depth-Anything (V2), and Marigold, with the resolution of  $1024 \times 576$ .

Method	Encoding	Denoising	Decoding	All
Depth-Anything (V2)	N/A 256.40	N/A 114 53	N/A 699 36	180.46 1070.29
DepthCrafter (Ours)	51.85	160.93	253.06	465.84

### Inference

### **DepthCrafter Inference**







Input video

**DepthCrafter Output** 

**DepthCrafter Output** 

### **Inference**

### **DepthCrafter Inference**



Input video



DepthCrafter Output





DepthCrafter Output

#### Method

- 합성 데이터셋의 장점을 활용하여 더 정밀한 깊이 디테일을 학습
- Small synthetic dataset ------- Depth를 추정하기 어려운 dataset 포함?







감사합니다.